

Módulo #1

Tarea #3: Escalamiento e ingeniería de variables

22 de septiembre de 2025

Raúl López Benítez

Lea las instrucciones para cada pregunta y resuelva con respecto a los datos que se señalan. En caso de preguntas teóricas añadir las referencias utilizadas (libros, artículos, sitios web). Sea breve y conciso.

Los ejercicios prácticos deben realizarse en Python. Se entregará un notebook por ejercicio en formato .pdf.

Teoría

1. Investiga qué es el **sobremuestreo** y **submuestreo**. ¿Para qué se usan? ¿En qué contexto? ¿Qué se debe considerar para usarlos?
2. Cuando hablamos de escalamiento de variables, podemos pensar en minmax scaler, standard scaler o robust scaler; sin embargo, existen otros escaladores. Investiga en qué consisten, contextos de uso y consideraciones de **MaxAbs scaler**, **Unit Vector (L1/L2)** y **Quantile Transform**. Guíate de como se definieron en clase.
3. Investiga los siguientes codificadores: **Binary Encoding**, **Frequency Encoding** y **Target Encoding**. Anota sus definiciones, consideraciones y supuestos como se realizó en clase.
4. Define las **transformaciones de Box-Cox**, su función, cálculo y tipos de transformaciones que se emplean en la práctica. Puedes elaborar una tabla con los valores de λ y la transformación que se le asigna a cada rango.
5. ¿Qué es la **maldición de la dimensionalidad**? Anota a qué se refiere este concepto, qué problemas trae consigo y qué se puede hacer para lidiar con ella.
6. Define qué es la **entropía** en el contexto de Teoría de la Información, ¿Cómo se liga el concepto de entropía e información?

Práctica

0.1. Análisis musical

Para este ejercicio debes utilizar el conjunto de datos `feature_songs.csv`.

Cierta plataforma para escuchar música quiere adaptar un nuevo algoritmo para recomendar música a sus usuarios. De manera experimental se toma una muestra de las canciones más escuchadas por los usuarios bajo un periodo de tiempo y se guardan sus características musicales:

- **Duration:** duración total de la canción (en segundos).
- **RMS (Root Mean Square Energy):** mide la energía promedio del audio; valores altos indican pasajes fuertes, mientras que valores bajos corresponden a partes suaves.
- **Tempo:** velocidad rítmica estimada de la canción, medida en *beats por minuto (BPM)*.
- **Zero Crossing Rate (ZCR):** frecuencia con la que la señal cruza el eje cero; valores altos suelen asociarse a sonidos ruidosos o percusivos.
- **Spectral Centroid:** centro de masa del espectro; indica si el sonido se percibe como más brillante/agudo (valores altos) o más grave/opaco (valores bajos).
- **Spectral Bandwidth:** anchura espectral; mide la dispersión de las frecuencias alrededor del centroide.
- **Spectral Rolloff:** frecuencia por debajo de la cual se concentra el 85 % de la energía espectral; se relaciona con el timbre del audio.
- **Spectral Contrast:** diferencia entre picos y valles en el espectro; describe cuán plana o marcada es la distribución espectral.
- **MFCCs (Mel-Frequency Cepstral Coefficients):** coeficientes que resumen la envolvente espectral en la escala mel; son representaciones del timbre y muy utilizados en reconocimiento de voz y música.
- **Chroma:** distribución de la energía a lo largo de las 12 notas musicales (do, do#, re, ...); útil para analizar armonía y progresiones de acordes.
- **Tonnetz:** representa relaciones tonales y armónicas (quintas, terceras, consonancias); permite caracterizar la tonalidad de una pieza musical.

Con estas variables se sugiere hacer una segmentación (análisis de clustering) para cada usuario y así encontrar grupos sobre las canciones que escucha y armar playlist personalizadas.

Tu tarea es analizar el conjunto de datos, realizar un análisis estadístico, escalar los datos y preparar un nuevo df reduciendo dimensiones para que posteriormente el equipo realice el análisis de clustering.

¿Qué otras variables agregarías tú y por qué? Justifica

0.2. Análisis de audio y texto

Para este ejercicio debes utilizar el conjunto de datos `audio_features_lyrics.xlsx`. Supongamos que eres contratado por una disquera, la cual quiere que su nueva propuesta musical tenga éxito. Su decisión estratégica es analizar a cantantes y bandas que han tenido éxito a lo largo de estos años, considerando las variables musicales de cada canción, así como las letras.

Una persona del equipo propone estudiar a Taylor Swift, pues cuentan con la información suficiente de su catálogo musical para tener una idea general de los datos y empezar el modelado.

El conjunto de datos contiene las siguientes variables:

- `album_name`: El nombre del álbum. NA si la canción fue lanzada por separado de uno de los álbumes de estudio o EPs de Taylor.
- `ep`: Logical. True si el álbum es un EP y False si es un álbum de estudio.
- `album_release`: La fecha en que el álbum fue lanzado (AAAA-MM-DD).
- `track_number`: El orden de la canción en el álbum o EP.
- `track_name`: El nombre de la canción.
- `artist`: El nombre del artista de la canción. Por lo general, Taylor Swift, pero mostrará otros artistas para canciones en las que Taylor solo aparece.
- `featuring`: Cualquier artista que aparezca en la pista.
- `bonus_track`: Logical. True si la canción es un bonus track, False en otro caso.
- `promotional_release`: La fecha en que la canción fue lanzada como sencillo promocional. NA si la canción nunca fue lanzada como sencillo promocional.
- `single_release`: La fecha en que la canción se lanzó como sencillo oficial. No disponible si la canción nunca se lanzó como sencillo oficial.

- `track_release`: La fecha en que la canción se lanzó públicamente por primera vez. Esta es la fecha más temprana entre `album_release`, `promotional_release` y `single_release`.
- `danceability`: cuán adecuada es una pista para bailar. 0.0 es lo menosailable, mientras que 1.0 es lo másailable.
- `energy`: medida perceptual de intensidad y actividad. 0.0 es igual a menor energía y 1.0 es igual a mayor energía.
- `key`: la tonalidad en la que está la pista. Los mapas enteros se corresponden con la notación estándar de Pitch Class.
- `loudness`: volumen de la pista en decibelios (dB), promediado en toda la pista.
- `mode`: modalidad de una pista (mayor/menor). 0 es menor, 1 es mayor.
- `speechness`: presencia de palabras habladas en una pista. Los valores superiores a 0.66 indican que la pista probablemente esté compuesta completamente de palabras habladas. Los valores entre 0.33 y 0.66 indican tanto música como habla. Los valores inferiores a 0.33 indican que la pista probablemente sea música u otras pistas sin habla.
- `acousticness`: confianza en que la pista es acústica. 0.0 representa baja confianza, 1.0 representa alta confianza.
- `instrumentalness`: Confianza en que la pista es instrumental (es decir, sin voces). 0.0 es baja confianza y 1.0 es alta confianza.
- `liveness`: Confianza en que la pista es una grabación en vivo (es decir, hay público presente). 0.0 es baja confianza, 1.0 es alta confianza.
- `valence`: Positividad musical que transmite la pista. 0.0 equivale a baja valencia (p. ej., triste, deprimido, enojado), 1.0 equivale alta valencia (p. ej., feliz, alegre, eufórico).
- `tempo`: Tempo estimado de la pista en pulsaciones por minuto (PPM).

- `time_signature`: Compás general estimado.
- `duration_ms`: Duración de la pista en milisegundos.
- `explicit`: Logical. True si la canción contiene letras explícitas, False en otro caso.
- `key_name`: corresponde directamente a la clave, pero el entero se convierte al nombre de la clave usando la notación de clase de tono (p. ej., 0 se convierte en C).
- `mode_name`: corresponde directamente al modo, pero el entero se convierte al nombre del modo (p. ej., 0 se convierte en menor).
- `key_mode`: una combinación de las variables `key_name` y `mode_name` (p. ej., C menor).
- `line`. El número de la línea en una canción.
- `lyric`. Verso en esa línea (string).
- `element`. Hace referencia a si esa línea es parte del coro, puente, intro, outro, verso 1, verso 2, etc.

Dado lo anterior, realiza lo siguiente:

1. Encuentra si hay valores ausentes. ¿Es necesario imputarlos?
2. Elige las variables que den información y elimina variables que no sean informativas o transfórmalas para tener información.
3. Utiliza la variable `lyric` para obtener información lírica, por ejemplo el número de líneas por canción, número de palabras, proporción de sílabas por canción, densidad léxica, longitud media de palabras, etc. Es importante considerar el tokenizado y remoción de stopwords.
4. Realiza un análisis estadístico. ¿Qué nos dicen las variables? ¿Qué podemos inferir de las variables?
5. Normaliza las variables categóricas que consideres necesarias.

6. Finalmente escala y codifica las variables.

Al final escribe tus conclusiones con respecto a tu análisis. Si el equipo te pide puntos clave sobre las canciones, ¿qué podrías decir? Por ejemplo, hablar sobre la duración de las canciones, propiedades de las letras, el tono, la bailabilidad, etc.

¿Qué variables agregarías tú a los datos para considerar en un análisis más complejo? (popularidad en redes, viralidad, análisis de sentimientos, momentos sociales, etc).

¿Qué variable definirías como una variable objetivo? Justifica (En el dataset no existe una variable objetivo, por lo que podrías definirla tú desde tu punto de vista)

Entregables

Para esta tarea los equipos deben ser de 4 o 5 personas. Se entregará un .pdf con las preguntas teóricas y un notebook por ejercicio en formato .pdf.