

MÓDULO INTEGRADOR · CIENCIA DE DATOS

Segmentación de clientes para campañas Starbucks

Este reporte presenta un flujo completo de análisis no supervisado para identificar perfiles de clientes a partir de datos demográficos, transacciones y comportamiento frente a ofertas. El objetivo es convertir la actividad histórica de la campaña en segmentos accionables para la toma de decisiones de marketing.

Problema de negocio

Starbucks cuenta con información de clientes, campañas y transacciones. La pregunta central es si existen grupos de clientes con patrones diferenciados de consumo e interacción con ofertas, de forma que sea posible diseñar acciones comerciales más precisas.

Dataset

Se utilizaron tres fuentes JSON: **profile** para datos demográficos, **portfolio** para atributos de ofertas y **transcript** para eventos cronológicos de clientes. La unidad final de análisis fue el cliente.


17kclientes
originales**16,694**clientes
modelados**4**clusters
GMM**82**variables
iniciales

EXPLORACIÓN DE DATOS


EDA y patrones iniciales

La exploración permitió identificar la distribución de variables clave, valores faltantes sistemáticos en datos demográficos y señales de comportamiento en gasto, visualización y finalización de ofertas.


Distribución de ingreso




Ingreso por género




Distribución de clientes por género




Relación entre edad e ingreso



Distribución de ticket promedio



Tiempo promedio para visualizar ofertas




Relación entre visualización y finalización

Se esperaba una tendencia positiva: clientes que visualizan más ofertas deberían finalizarlas con mayor frecuencia. Sin embargo, la nube de puntos muestra dispersión, lo cual sugiere que ver una oferta no implica necesariamente aprovecharla. Ambas variables aportan información

diferente al proceso de segmentación.

Relación entre tasa de visualización y finalización



PREPARACIÓN

Ingeniería de variables y limpieza

El archivo transcript fue transformado en una tabla de cliente, generando métricas de interacción, tiempos de respuesta, canales, tipos de oferta y transacciones.

01

Eventos

Se separaron eventos recibidos, vistos, completados y transacciones para reconstruir el flujo de interacción por cliente.

02

Variables

Se crearon tasas de visualización, finalización, ticket promedio, frecuencia de compra y tiempos entre eventos.

03

Nulos

Los nulos de comportamiento se trataron con banderas; ingreso se imputó con MICE y género con un modelo basado en Random Forest.

04

Outliers

Se utilizó IsolationForest con contaminación de 1.8%, considerando el análisis previo de percentiles extremos.

Tratamiento de datos faltantes

Los registros con edad 118, ingreso nulo y género faltante fueron interpretados como clientes con información demográfica incompleta, no como errores aislados. Dado que estos clientes sí presentaban interacción y transacciones, se conservaron para no perder comportamiento comercial.

Valores atípicos

El análisis univariado permitió ubicar extremos en edad y gasto promedio. Posteriormente, IsolationForest evaluó el comportamiento multivariado de los registros para identificar casos atípicos considerando todas las variables en conjunto.

PREPROCESAMIENTO

Escalamiento y selección de variables

Para evitar que variables monetarias o de frecuencia dominaran el modelo, las variables fueron escaladas antes de aplicar reducción de dimensionalidad y clustering.

Escalamiento

El escalamiento permite que variables con unidades diferentes — por ejemplo ingreso, gasto, tasas y tiempos— participen de forma comparable en los modelos basados en distancia.

Multicolinealidad


Se aplicó VarClusHi para reducir redundancia entre variables altamente relacionadas. Esto permitió conservar variables representativas y disminuir ruido antes de PCA.

REDUCCIÓN


PCA y t-SNE

PCA ayudó a condensar información y t-SNE permitió visualizar estructura local entre clientes. t-SNE se utilizó como herramienta exploratoria, no como entrada directa para formar clusters.

Proyección PCA



Visualización t-SNE




MODELADO NO SUPERVISADO

Número óptimo y clustering

Se evaluó el número de grupos con inercia, Davies-Bouldin y Silhouette. Aunque KMeans mostró buena separación visual, GMM ofreció perfiles más interpretables para el análisis final.

Evaluación del número óptimo de clusters




Lectura de métricas


Métrica	Mejor valor	Interpretación
Inercia	Más bajo	Clusters más compactos respecto a sus centroides.

Métrica	Mejor valor	Interpretación
Davies-Bouldin	Más bajo	Mejor separación entre grupos y menor dispersión interna.
Silhouette	Más alto	Mayor cohesión dentro del cluster y separación frente a otros.


KMeans sobre t-SNE




GMM sobre t-SNE



KMeans en espacio PCA 3D



GMM en espacio PCA 3D



Aunque GMM presenta mayor solapamiento visual que KMeans, sus grupos ofrecen una lectura de negocio más clara. Por ello, el perfilamiento final se realizó con los clusters generados mediante GMM.

RESULTADOS

Perfilamiento de clusters

GMM

Los segmentos se diferencian principalmente por gasto, transacciones, respuesta a promociones y tamaño del grupo. Edad e ingreso no explican por sí solos la separación.

Cluster 0

17.8% clientes

Activos promocionales de bajo ticket

2,972
clientes**\$25**
gasto prom.**72.9%**
visualización**0.2%**
finalización

- Grupo con edad promedio más alta y fuerte concentración masculina.
- Visualiza ofertas con frecuencia, pero casi no las finaliza.
- Mantiene bajo gasto total y ticket promedio; conviene trabajar incentivos más simples o personalizados.

Cluster 1

28.6% clientes

Alto valor con alta conversión

4,781
clientes**\$137**
gasto prom.**80.8%**
visualización**66.3%**
finalización

- Clientes de alto valor: mayor gasto, ticket y frecuencia de compra.
- Presentan la mejor conversión una vez que visualizan ofertas.
- Segmento prioritario para campañas de retención, beneficios y promociones tipo BOGO/descuento.

Cluster 2

44.6% clientes

Base masiva de alto consumo

7,450

clientes

\$134

gasto prom.

78.4%

visualización

48.1%

finalización

- Es el grupo más grande de la muestra, con cerca de la mitad de los clientes.
- Gasto y ticket promedio similares al cluster 1, aunque con conversión ligeramente menor.
- Representa la base comercial más relevante por volumen y comportamiento constante.

Cluster 3

8.9% clientes

Baja actividad comercial

1,491

clientes

\$16

gasto prom.

74.7%

visualización

0.1%

finalización

- Grupo pequeño, con edad promedio alta y mayor proporción de hombres.
- Tiene el menor gasto, ticket y número de transacciones.
- Aunque revisa ofertas, prácticamente no las completa; requiere estrategias de reactivación.

Tabla resumen de segmentos

La tabla integra métricas demográficas, transaccionales y promocionales por cluster. Los porcentajes corresponden al promedio del grupo.

cluster	clientes	% clientes	edad	ingreso	% hombres	% mujeres	gasto prom.	ticket	trx prom.	ofertas	visualización	finalización	finaliz. vistas	hrs ver	hrs comp
0	2972	17.8%	71.35	\$60,226	75.0%	24.0%	\$25	\$5.12	5.21	4.44	72.9%	0.2%	0.3%	33.90	0.02
1	4781	28.6%	58.84	\$67,866	54.3%	44.1%	\$137	\$16.22	9.68	4.30	80.8%	66.3%	89.0%	30.33	67.82
2	7450	44.6%	59.19	\$68,163	53.4%	45.3%	\$134	\$16.62	9.18	4.76	78.4%	48.1%	67.2%	31.18	64.78
3	1491	8.9%	73.41	\$59,955	80.3%	19.2%	\$16	\$3.52	4.71	4.12	74.7%	0.1%	0.2%	32.66	0.01

Lectura ejecutiva

Los clusters 1 y 2 concentran a los clientes de mayor valor comercial. El cluster 2 destaca por su tamaño, mientras que el cluster 1 presenta mejor tasa de finalización una vez que visualiza ofertas. Los clusters 0 y 3 muestran menor consumo; sin embargo, el cluster 0 conserva alta interacción digital, mientras que el cluster 3 requiere estrategias de reactivación.

CIERRE

Conclusiones

El análisis demuestra que la segmentación no supervisada permite convertir datos transaccionales y promocionales en perfiles accionables para marketing.

1. Comportamiento sobre demografía

Las diferencias más útiles no provienen solo de edad o ingreso, sino de cómo los clientes compran, visualizan ofertas y responden a campañas.

2. Segmentos accionables

GMM permitió obtener cuatro grupos con lectura comercial: alto valor, base masiva, usuarios promocionales de bajo ticket y baja actividad.

3. Uso estratégico

Los segmentos pueden utilizarse para priorizar campañas, ajustar tipos de oferta y diseñar acciones diferenciadas de retención o reactivación.

DATOS DEL ALUMNO

Erick Adrián Orozpe Frías

Diplomado en Ciencia de Datos · Facultad de Estudios Superiores Acatlán · UNAM

Mtra. Angélica León González