

Práctica 2

Diplomado en Ciencia de Datos — Módulo 5

Conjunto de datos

Considere el siguiente conjunto de datos.

LIMIT_BAL	SEX	EDUCATION	...	PAY_AMT4	PAY_AMT5	PAY_AMT6	default.payment.next.month
160000.0	2	2	...	3675.0	3821.0	8256.0	0
30000.0	2	3	...	2600.0	0.0	1600.0	1
180000.0	1	2	...	1421.0	2386.0	1964.0	0
30000.0	2	2	...	0.0	0.0	0.0	0
80000.0	2	5	...	3349.0	2784.0	3000.0	0

La tabla proporcionada registra de forma resumida el uso de las tarjetas de crédito de clientes de un Banco de Taiwan, contiene información del cliente, de la línea de crédito, sus pagos, etc.

Diccionario de datos

- **CUSTOMER_ID**: Identificador de cada cliente
- **LIMIT_BAL**: Monto de la línea de crédito
- **SEX**: Género (1=masculino, 2=femenino)
- **EDUCATION**: (1=preparatoria, 2=universidad, 3=secundaria, 4=otros, 5=desconocido, 6=desconocido, 0=nulo)
- **MARRIAGE**: Estatus marital (1=casado, 2=soltero, 3=otros, 0=nulo)
- **AGE**: Edad en años.
- **PAY_0**: Estatus de pago en Septiembre, 2005 (-2=no uso (non use), 0=uso, -1=pago correcto, 1=pago retrasado por un mes, 2=pago retrasado por dos meses, ... 8=pago retrasado por ocho meses, 9=pago retrasado por nueve o más meses).
- **PAY_2**: Estatus de pago en Agosto, 2005 (La escala es igual que en PAY_0).
- **PAY_3**: Estatus de pago en Julio, 2005 (La escala es igual que en PAY_0).
- **PAY_4**: Estatus de pago en Junio, 2005 (La escala es igual que en PAY_0).
- **PAY_5**: Estatus de pago en Mayo, 2005 (La escala es igual que en PAY_0).
- **PAY_6**: Estatus de pago en Abril, 2005 (La escala es igual que en PAY_0).
- **BILL_AMT1**: Monto por pagar en Septiembre, 2005
- **BILL_AMT2**: Monto por pagar en Agosto, 2005
- **BILL_AMT3**: Monto por pagar en Julio, 2005

- **BILL_AMT4**: Monto por pagar en Junio, 2005
- **BILL_AMT5**: Monto por pagar en Mayo, 2005
- **BILL_AMT6**: Monto por pagar en Abril, 2005
- **PAY_AMT1**: Cantidad pagada en Septiembre, 2005
- **PAY_AMT2**: Cantidad pagada en Agosto, 2005
- **PAY_AMT3**: Cantidad pagada en Julio, 2005
- **PAY_AMT4**: Cantidad pagada en Junio, 2005
- **PAY_AMT5**: Cantidad pagada en Mayo, 2005
- **PAY_AMT6**: Cantidad pagada en Abril, 2005
- **default.payment.next.month**: Incumplimiento de pago (1=si, 0=no)

Regresión

Estime de la mejor forma posible las siguientes variables objetivo:

- **PAY_AMT1**: Cantidad pagada en Septiembre, 2005. Para esta solución deben usarse los conjuntos *train_PAY_AMT1.csv* y *val_PAY_AMT1.csv*.

Clasificación

Pruebe los modelos de clasificación vistos en clase para estimar de la mejor forma posible la siguiente variable objetivo:

- **default.payment.next.month**: Para esta solución deben usarse los conjuntos *train_default.csv* y *val_default.csv*.

Entregables

- Regresión:
 - (5 puntos) Conjunto de validación calificado en formato *.csv* indicando la variable objetivo estimada.
- Clasificación:
 - (5 puntos) Conjunto de validación calificado en formato *.csv* indicando la variable objetivo estimada.
- Notebook con el ETL, los entrenamientos y las arquitecturas probadas
- En caso de ser necesario: función que reciba el dataset crudo, realice las transformaciones necesarias, aplique el modelo y arroje el vector de predicciones.

Los archivos deben tener la siguiente estructura:

ApellidoapaternoApellidoomaternoNombre1Nombre2_modelo.csv

, donde *modelo* puede tomar cualquiera de los siguientes valores, éstos en función de la predicción:

- PAYAMT1
- DefaultPayment

Dichas entregas deben realizarse en un csv con las columnas **ACCOUNT_ID** y **y_hat**.

Consideraciones

- La práctica debe resolverse completamente en Python.
- Las únicas restricciones de arquitecturas son las siguientes:
 - Deben de usarse embeddings para las variables discretas.
 - Deben usarse pipelines con ColumnTransformer y de ser posible, que procesen todo el dataset
 - Se debe de probar el uso de autoencoders para los datos.
- Los entregables deben contener únicamente las columnas *ACCOUNT_ID* y las predicciones, la cuales deben ser almacenadas en una columna llamada *y_hat*.
- La calificación de los conjuntos de evaluación estará sujeta a las métricas de ajuste que arrojen al compararlos con aquella persona que obtenga la mayor calificación, es decir, el benchmark es el mayor score obtenido por modelo.